# Laporan Praktikum 3 Data Mining : Ensemble Method dan Class Imbalance

Intifada Afkar Lazain Muhammad(5054251029)

1. Eksplorasi Data dan Analisis (EDA)
   Pada proses ini saya mengecek cuplikan data agar mengetahui gambaran besar fitur fitur dari data.

| | Time | V1 | V2 | V3 | V4 | V5 | V6 | V7 | V8 | V9 | ... | V21 | V22 | V23 | V24 | V25 | V26 | V27 | V28 | Amount | Class |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | 0.0 | -1.359807 | -0.072781 | 2.536347 | 1.378155 | -0.338321 | 0.462388 | 0.239599 | 0.098698 | 0.363787 | ... | -0.018307 | 0.277838 | -0.110474 | 0.066928 | 0.128539 | -0.189115 | 0.133558 | -0.021053 | 149.62 | 0 |
| 1 | 0.0 | 1.191857 | 0.266151 | 0.166480 | 0.448154 | 0.060018 | -0.082361 | -0.078803 | 0.085102 | -0.255425 | ... | -0.225775 | -0.638672 | 0.101288 | -0.339846 | 0.167170 | 0.125895 | -0.008983 | 0.014724 | 2.69 | 0 |
| 2 | 1.0 | -1.358354 | -1.340163 | 1.773209 | 0.379780 | -0.503198 | 1.800499 | 0.791461 | 0.247676 | -1.514654 | ... | 0.247998 | 0.771679 | 0.909412 | -0.689281 | -0.327642 | -0.139097 | -0.055353 | -0.059752 | 378.66 | 0 |
| 3 | 1.0 | -0.966272 | -0.185226 | 1.792993 | -0.863291 | -0.010309 | 1.247203 | 0.237609 | 0.377436 | -1.387024 | ... | -0.108300 | 0.005274 | -0.190321 | -1.175575 | 0.647376 | -0.221929 | 0.062723 | 0.061458 | 123.50 | 0 |
| 4 | 2.0 | -1.158233 | 0.877737 | 1.548718 | 0.403034 | -0.407193 | 0.095921 | 0.592941 | -0.270533 | 0.817739 | ... | -0.009431 | 0.798278 | -0.137458 | 0.141267 | -0.206010 | 0.502292 | 0.219422 | 0.215153 | 69.99 | 0 |

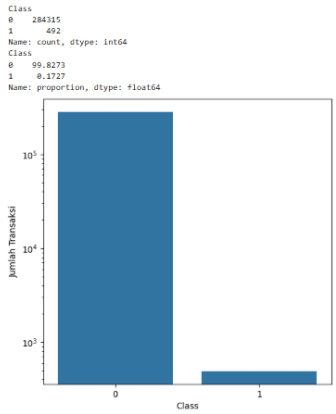
   Terlihat bahwa semua fitur pada data sudah bersih dan berisi float dan 1 int yaitu class yang dapat berisi 1 atau 0. Data seperti bagus karena tidak diperlukan langkah encode dan penerjemahan data karena sudah berisi numerik.

   Selanjutnya, saya mengecek distribusi numerik data.

| | V1 | V2 | V3 | V4 | V5 | V6 | V7 | V8 | V9 | ... | V21 | V22 | V23 | V24 | V25 | V26 | V27 | V28 | A |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| | 2.848070e+05 | 2.848070e+05 | 2.848070e+05 | 2.848070e+05 | 2.848070e+05 | 2.848070e+05 | 2.848070e+05 | 2.848070e+05 | 2.848070e+05 | 2.848070e+05 | ... | 2.848070e+05 | 2.848070e+05 | 2.848070e+05 | 2.848070e+05 | 2.848070e+05 | 2.848070e+05 | 2.848070e+05 | 2.848070e+05 | 284807 |
| | 1.168375e-15 | 3.416908e-16 | -1.379537e-15 | 2.074095e-15 | 9.604066e-16 | 1.487313e-15 | -5.556467e-16 | 1.213481e-16 | -2.406331e-15 | ... | 1.654067e-16 | -3.568593e-16 | 2.578648e-16 | 4.473266e-15 | 5.340915e-16 | 1.683437e-15 | -3.660091e-16 | -1.227390e-16 | 88. |
| | 1.958696e+00 | 1.651309e+00 | 1.516255e+00 | 1.415869e+00 | 1.380247e+00 | 1.332271e+00 | 1.237094e+00 | 1.194353e+00 | 1.098632e+00 | ... | 7.345240e-01 | 7.257016e-01 | 6.244603e-01 | 6.056471e-01 | 5.212781e-01 | 4.822270e-01 | 4.036325e-01 | 3.300833e-01 | 250. |
| | -5.640751e+01 | -7.271573e+01 | -4.832559e+01 | -5.683171e+00 | -1.137433e+02 | -2.616051e+01 | -4.355724e+01 | -7.321672e+01 | -1.343407e+01 | ... | -3.483038e+01 | -1.093314e+01 | -4.480774e+01 | -2.836627e+00 | -1.029540e+01 | -2.604551e+00 | -2.256568e+01 | -1.543008e+01 | 0. |
| | -9.203734e-01 | -5.985499e-01 | -8.903648e-01 | -8.486401e-01 | -6.915971e-01 | -7.682956e-01 | -5.540759e-01 | -2.086297e-01 | -6.430976e-01 | ... | -2.283949e-01 | -5.423504e-01 | -1.618463e-01 | -3.545861e-01 | -3.171451e-01 | -3.269839e-01 | -7.083953e-02 | -5.295979e-02 | 5. |
| | 1.810880e-02 | 6.548556e-02 | 1.798463e-01 | -1.984653e-02 | -5.433583e-02 | -2.741871e-01 | 4.010308e-02 | 2.235804e-02 | -5.142873e-02 | ... | -2.945017e-02 | 6.781943e-03 | -1.119293e-02 | 4.097606e-02 | 1.659350e-02 | -5.213911e-02 | 1.342146e-03 | 1.124383e-02 | 22. |
| | 1.315642e+00 | 8.037239e-01 | 1.027196e+00 | 7.433413e-01 | 6.119264e-01 | 3.985649e-01 | 5.704361e-01 | 3.273459e-01 | 5.971390e-01 | ... | 1.863772e-01 | 5.285536e-01 | 1.476421e-01 | 4.395266e-01 | 3.507156e-01 | 2.409522e-01 | 9.104512e-02 | 7.827995e-02 | 77. |
| | 2.454930e+00 | 2.205773e+01 | 9.382558e+00 | 1.687534e+01 | 3.480167e+01 | 7.330163e+01 | 1.205895e+02 | 2.000721e+01 | 1.559499e+01 | ... | 2.720284e+01 | 1.050309e+01 | 2.252841e+01 | 4.584549e+00 | 7.519589e+00 | 3.517346e+00 | 3.161220e+01 | 3.384781e+01 | 25691. |

   Terlihat bahwa data sebenarnya mayoritas sangat normal dan setara, namun di fitur waktu dan amount fitur tersebut mempunyai nilai yang sangat tinggi sehingga harus dilakukan scaling agar tidak mendominasi fitur lain.

   Kemudian akan di cek untuk distribusi kelasnya apakah seimbang atau tidak.




Terlihat bahwa data sangat imbalance class 1 sangat rendah diangka 0.17 persen hal ini tentu harus ditangani menggunakan SMOTE dengan harapan akan membantu model memprediksi kelas minoritas dengan lebih baik.

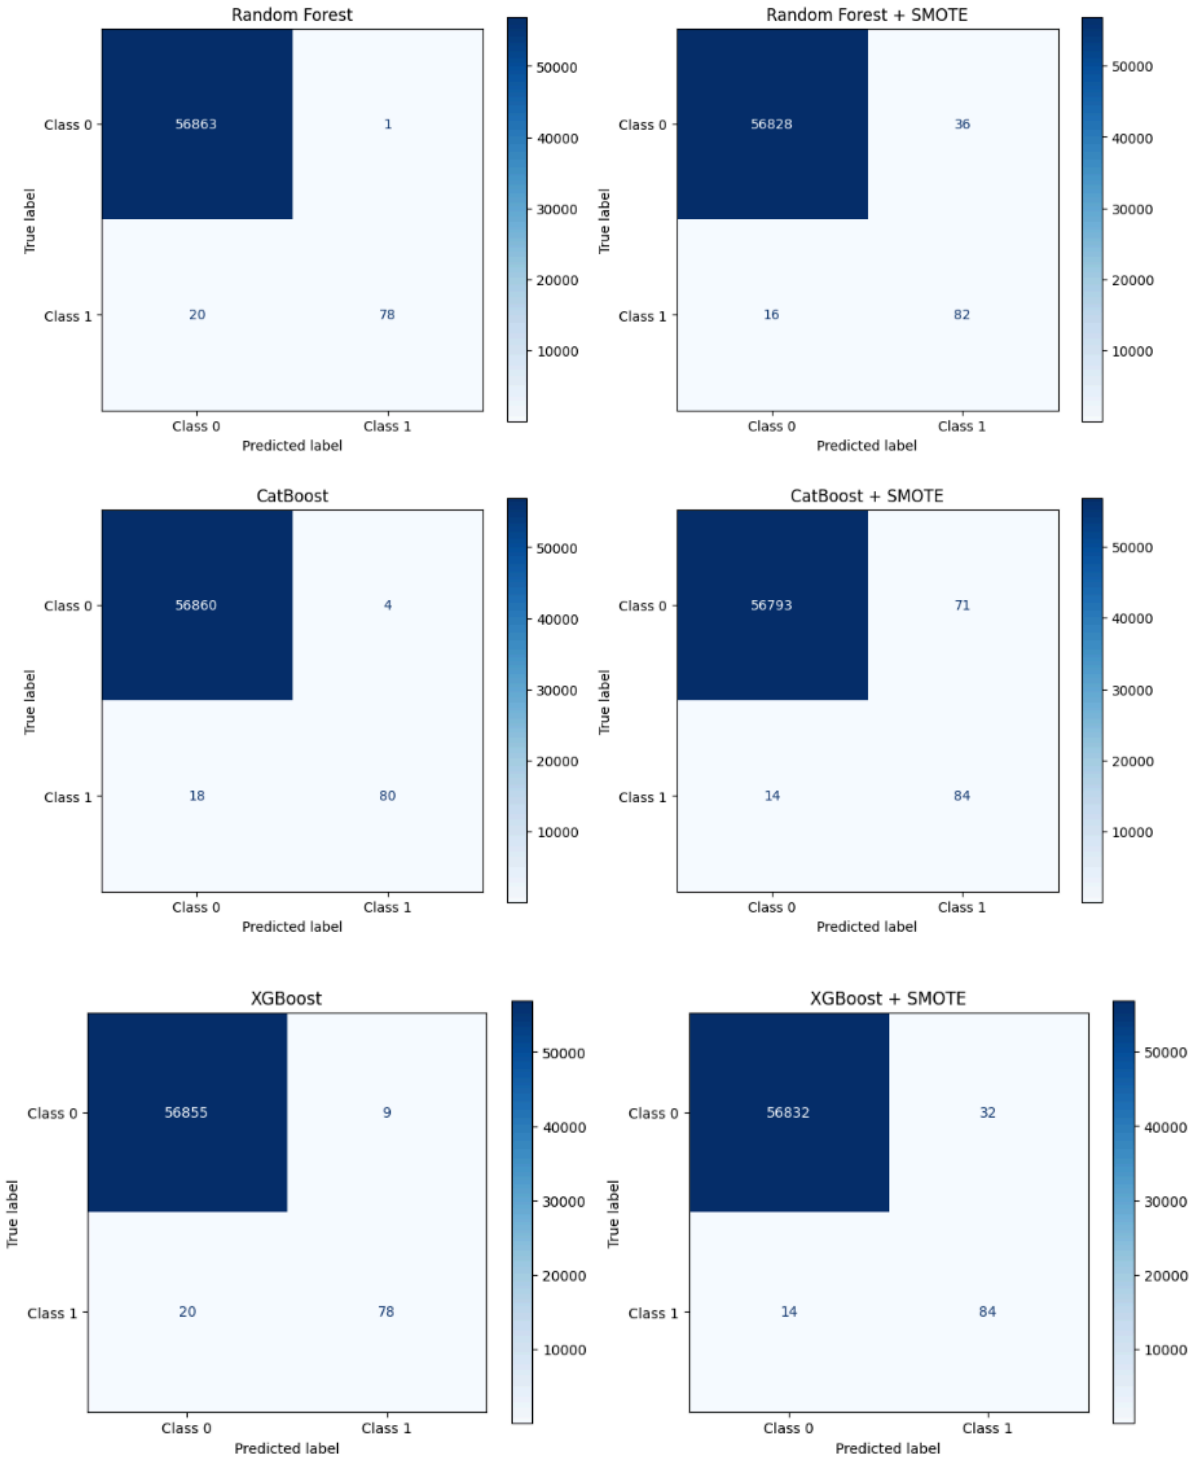
2. Pipeline dan Pemodelan
   Pipeline yang digunakan adalah StandardScaler dan variasi antara menggunakan SMOTE dan tidak dengan model yang diinginkan untuk model yang saya pilih untuk uji coba yaitu randomforestclassifier, catboostclassifier, xgboost. Model model tersebut saya pilih karena peforma secara keseluruhan yang terkenal paling baik diantara model lain dan juga model model tersebut merupakan model ensemble sesuai dengan bab tugas.

3. Perbandingan Peforma Model dan Pengaruh SMOTE

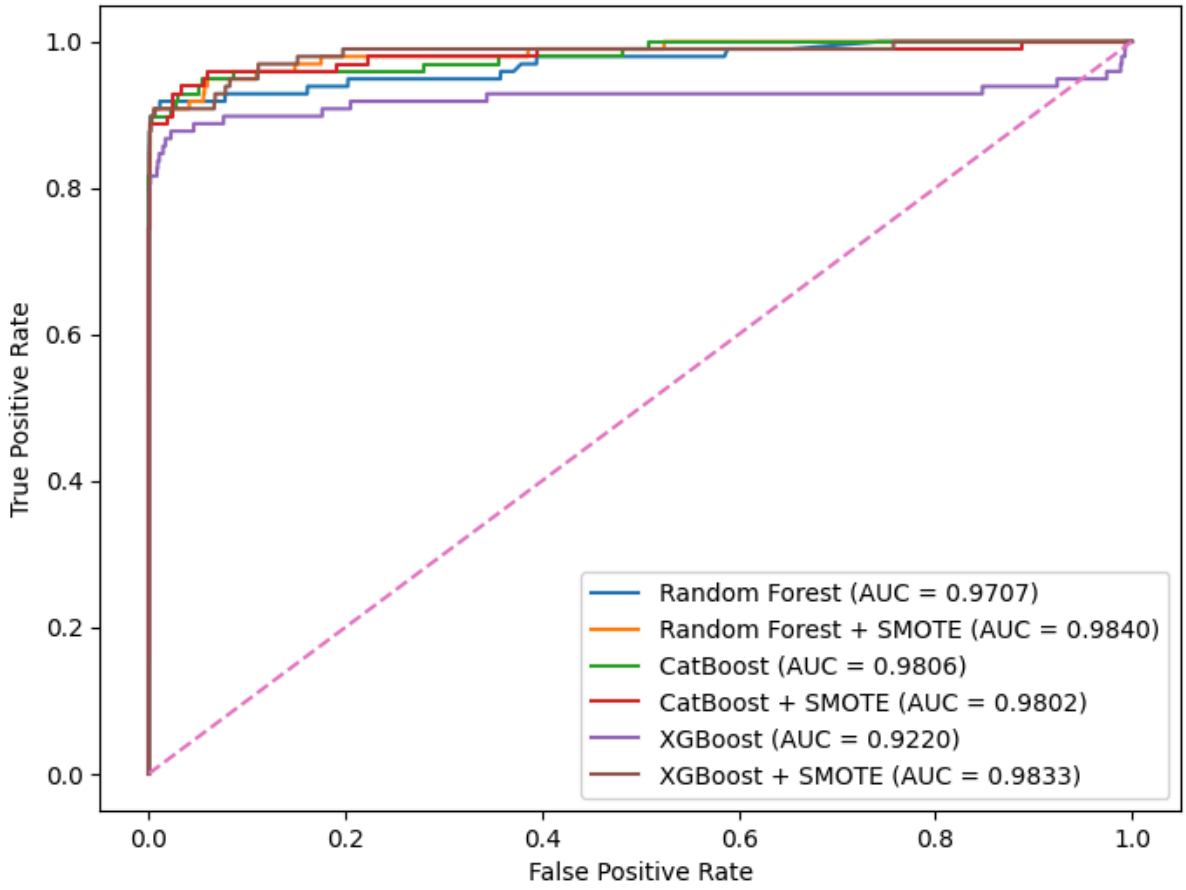
| | Model | Precision | Recall | F1-score | ROC-AUC | Average Precision | Accuracy |
|---|---|---|---|---|---|---|---|
| 0 | Random Forest | 0.987342 | 0.795918 | 0.881356 | 0.970676 | 0.884758 | 0.999631 |
| 1 | Random Forest + SMOTE | 0.694915 | 0.836735 | 0.759259 | 0.983979 | 0.857452 | 0.999087 |
| 2 | CatBoost | 0.952381 | 0.816327 | 0.879121 | 0.980622 | 0.881434 | 0.999614 |
| 3 | CatBoost + SMOTE | 0.541935 | 0.857143 | 0.664032 | 0.980175 | 0.850152 | 0.998508 |
| 4 | XGBoost | 0.896552 | 0.795918 | 0.843243 | 0.922011 | 0.775902 | 0.999491 |
| 5 | XGBoost + SMOTE | 0.724138 | 0.857143 | 0.785047 | 0.983318 | 0.867149 | 0.999192 |

Karena ini adalah model untuk anomaly detection dan classnya sangat imbalance ke positif maka kita hanya akan mempertimbangkan aspek recallnya karena pada task seperti ini mendeteksi anomaly dengan benar lebih berguna daripada mendeteksi nilai false yang mayoritas maka dari itu jika dilihat dari tabel diatas model terbaik untuk task ini adalah XGboost + SMOTE karena memiliki recall terbesar dan memiliki accuracy lebih baik daripada Catboost + SMOTE. Terlihat juga bahwa model dengan SMOTE bisa mendeteksi anomaly

dengan lebih baik daripada tidak menggunakan SMOTE.




Hasil dari confussion matrix juga memberi kesimpulan yang sama dimana XGboost + SMOTE merupakan kombinasi terbaik karena mampu memprediksi kelas 1 lebih baik dan akurasi keseluruhan lebih baik daripada CatBoost + SMOTE.




Pada grafik ROC-AUC untuk class positif terlihat perbedaan signifikan dari XGBoost default dengan XGBoost + SMOTE hal ini mengonfirmasi bahwa SMOTE sangat membantu model untuk mendeteksi kelas minoritas. Walau Random Forest + SMOTE memiliki skor terbaik pada ROC-AUC tapi XGBoost + SMOTE masih memiliki peforma sangat dengan dengan clasifikasi kelas minoritas dengan lebih baik, oleh karena itu saya berkesimpulan bahwa XGBoost + SMOTE adalah model terbaik untuk task ini.