Tugas Sequential Pattern
Data Mining Praktikum
Intifada Afkar Lazain Muhammad (5054251029)

1. Hasil Eksplorasi dan Pembersihan Data
   Dataset Online Retail.xlsx berisi 8 kolom yaitu InvoiceNo(Id belanja), StockCode, Deskripsi barang yang dibeli, InvoiceDate, UnitPrice, CustomerID, Country, Quantity. Namun yang akan digunakan hanya CustomerID, InvoiceNo, InvoiceDate, dan Deskripsi barang yang dibeli karena kita ingin mengetahui pola urutan pembelian barang dari setiap pelanggan berdasarkan waktu transaksi.

   Pada laporan ternyata diberitahu bahwa ada description yang kosong, transaksi yang dibatalkan(ditandai dengan awalan huruf "C"), baris dengan Quantity bernilai negatif atau nol, serta baris dengan CustomerID kosong karena sequence disusun per pelanggan sehingga diperintahkan untuk menghapus baris yang mengandung nilai invalid tersebut. Jumlah baris awal adalah 541.909, jumlah invoice awal adalah 25.900, dan jumlah pelanggan awal adalah 4.372, saat sudah di cleaning jumlah baris menjadi 397.924, jumlah invoice menjadi 18.536, dan jumlah pelanggan menjadi 4.339.

   Setelah itu data diurutkan berdasarkan CustomerID, InvoiceDate, dan InvoiceNo, lalu item pada satu invoice dikelompokkan menjadi satu itemset. Kemudian setiap pelanggan disusun menjadi satu sequence berisi daftar itemset yang urut secara waktu dan disimpan dalam bentuk list of list agar dapat diproses pada saat menerapkan algoritma PrefixSpan.

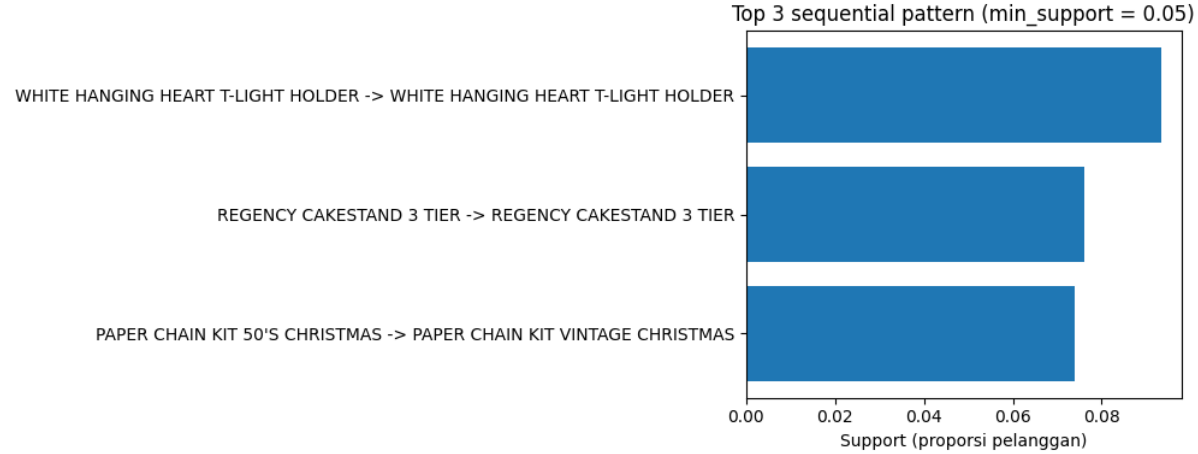
2. Pola Berurutan yang Dihasilkan Beserta Analisis Evaluasi
   Algoritma yang dipilih adalah PrefixSpan dengan panjang pola minimal 2 dan maksimal 3. Pencarian pola berurutan dilakukan pengetesan min_support dengan nilai 0.01, 0.02, 0.03, dan 0.05 (relatif terhadap jumlah pelanggan) untuk membandingkan hasil. Hasil dari min_support 0.01 menghasilkan 75.526 pola dengan waktu 101,9 detik, min_support 0.02 menghasilkan 5.512 pola dengan waktu 17,8 detik, dan min_support 0.03 menghasilkan 888 pola dengan waktu 6,6 detik yang masih merupakan jumlah yang terlalu banyak untuk dianalisis terlebih tugas hanya menginginkan top 3. Hasil dari min_support 0.05 menghasilkan 71 pola dengan waktu 1,3 detik yang cukup ringkas dan mudah dibaca serta cukup untuk menjawab soal, kelebihan dari meningkatkan min_support selain meringkas juga memastikan polanya sering terjadi pada pembelian pelanggan. Berikut hasil pola berurutan beserta nilai support dan confidence serta grafik top 3 pola dari min_support 0.05

Total pola berurutan yang dihasilkan: 71 (10 Pola Teratas):

	pattern_str	support_count	support	confidence
0	WHITE HANGING HEART T-LIGHT HOLDER -> WHITE HA...	405	0.093339	0.473131
1	REGENCY CAKESTAND 3 TIER -> REGENCY CAKESTAND ...	330	0.076054	0.374574
2	PAPER CHAIN KIT 50'S CHRISTMAS -> PAPER CHAIN ...	321	0.073980	0.523654
3	GREEN REGENCY TEACUP AND SAUCER -> ROSES REGEN...	318	0.073289	0.821705
4	JUMBO BAG RED RETROSPOT -> JUMBO BAG RED RETRO...	312	0.071906	0.491339
5	REGENCY CAKESTAND 3 TIER -> ROSES REGENCY TEAC...	299	0.068910	0.339387
6	GREEN REGENCY TEACUP AND SAUCER -> PINK REGENC...	294	0.067758	0.759690
7	LUNCH BAG CARS BLUE -> LUNCH BAG RED RETROSPOT	293	0.067527	0.611691
8	RED HANGING HEART T-LIGHT HOLDER -> WHITE HANG...	293	0.067527	0.761039
9	HEART OF WICKER LARGE -> HEART OF WICKER SMALL	292	0.067297	0.602062

3 Pola Berurutan Terbaik Berdasarkan Nilai Support Tertinggi:

	pattern_str	support_count	support	confidence
0	WHITE HANGING HEART T-LIGHT HOLDER -> WHITE HA...	405	0.093339	0.473131
1	REGENCY CAKESTAND 3 TIER -> REGENCY CAKESTAND ...	330	0.076054	0.374574
2	PAPER CHAIN KIT 50'S CHRISTMAS -> PAPER CHAIN ...	321	0.073980	0.523654



3. Terlihat dari 3 pola terbaik bahwa 2 dari 3 pola membeli barang yang sama secara berurutan, artinya banyak pelanggan yang memiliki pola sequential cenderung melakukan pembelian berulang terhadap produk yang sama, sedangkan untuk pasangan pola ke-3 yaitu PAPER CHAIN KIT 50'S CHRISTMAS dan PAPER CHAIN KIT VINTAGE CHRISTMAS sama-sama merupakan perlengkapan natal karena pada saat natal orang-orang tidak hanya membeli satu hiasan namun banyak variasi untuk menghias lingkungan mereka. Yang bisa dilakukan toko ritel adalah memberi bundling ke produk yang sejenis agar pelanggan tertarik untuk berbelanja kembali ke toko, serta pada saat musim tertentu seperti natal membuat paket bundling hiasan natal agar lebih efisien bagi pelanggan dan meningkatkan ketertarikan membeli, atau dengan memberi diskon khusus untuk pelanggan setia karena persentase support yang besar juga menunjukkan tingginya pembelian berulang (repeat order) dari pelanggan.

   Untuk kesimpulan dari 3 pola berurutan terbaik secara eksplisit adalah WHITE HANGING HEART T-LIGHT HOLDER -> WHITE HANGING HEART T-LIGHT HOLDER memiliki support 0,0933 (sekitar 9% pelanggan) dan confidence 0,4731,

REGENCY CAKESTAND 3 TIER -> REGENCY CAKESTAND 3 TIER memiliki support 0,0761 (sekitar 8% pelanggan) dan confidence 0,3746, serta PAPER CHAIN KIT 50'S CHRISTMAS -> PAPER CHAIN KIT VINTAGE CHRISTMAS memiliki support 0,0740 (sekitar 7% pelanggan) dan confidence 0,5237.